Introducción a
Análisis de Datos

Trabajo Práctico Integrador

TPI - Análisis Telco Customer Churn



Integrantes — Grupo 2

Alejo Nehuen Paiva
Gonzalo Suarez
Tomas Barrios
Agustina Seggiaro

Profesor:
Enzo Zotti

Fecha:
16/11/2026

Análisis-datos TPI

Definición del problema de negocio

En principio, **los datos están sucios, pero de forma "silenciosa"**. No tienen nulos explícitos ni duplicados, da todo en cero y parece limpio. Los problemas aparecen recién cuando se observa con más cuidado.

Una empresa de telecomunicaciones pierde ingresos cada vez que un cliente se da de baja (*churn*). Retener a un cliente existente suele ser menos costoso que captar uno nuevo, por lo que identificar **qué características distinguen a los clientes que se van de los que permanecen** permite diseñar acciones de retención focalizadas (ofertas, cambios de contrato, mejoras de servicio).

Pregunta central: ¿Qué perfiles de cliente, servicios contratados y condiciones comerciales están asociados a una mayor tasa de abandono?

Calidad de los datos: un conjunto "sucio"

El dataset contiene 7.043 clientes y 21 atributos. A simple vista no presenta nulos ni duplicados (0 valores nulos nativos, 0 filas duplicadas, 0 `customerID` repetidos), pero la inspección detallada revela problemas que, de ignorarse, distorsionarían el análisis:

Problema detectado	Detalle	Tratamiento
Nulos ocultos como texto	`TotalCharges` contiene 11 valores en blanco (`" "`) que pandas no reconoce como nulos.	Conversión con `pd.to_numeric(errors="coerce")`, que los transforma en `NaN`.
Tipo de dato incorrecto	Por esos blancos, `TotalCharges` se carga como texto aunque es un monto. Sin convertirla, no se puede sumar ni promediar.	Casteo a `float`.
Origen de los vacíos	Los 11 casos corresponden a clientes con `tenure = 0` (recién incorporados, sin facturación acumulada) y ninguno abandonó.	Se decide si excluirlos o imputar 0, documentando el criterio.
Codificación inconsistente	`SeniorCitizen` usa 0/1, mientras que el resto de las binarias usa `Yes` / `No`.	Unificar la codificación para el análisis.

Problema detectado	Detalle	Tratamiento
Categorías redundantes	`No phone service` (682 casos) y `No internet service` (1.526) repiten información que ya está en `PhoneService` e `InternetService`.	Evaluar si agruparlas con `No` según el análisis.
Nomenclatura heterogénea	Mezcla de estilos (`tenure` en minúscula, `customerID` en camelCase, `MonthlyCharges` en PascalCase).	Renombrar a un formato uniforme.
Atributos irrelevantes	`customerID` es solo un identificador, sin valor predictivo.	Eliminar antes de modelar.
Clases desbalanceadas	`Churn`: 73,5 % `No` vs 26,5 % `Yes`.	Considerar al interpretar métricas, para no sobrevalorar un análisis que "acierta" prediciendo siempre `No`.

Conclusión del apartado: la limpieza no es opcional. Sin ella, `TotalCharges` no podría usarse en ninguna agregación y las conclusiones se apoyarían en datos mal tipificados.

Variable objetivo

`Churn` (cualitativa nominal binaria): `Yes` = el cliente se dio de baja, `No` = continúa. Es el fenómeno que se busca explicar, y el resto de los atributos funcionan como variables explicativas.

Hipótesis analíticas

Son supuestos de partida, a contrastar con los datos (no son resultados):

1. **H1 – Contrato:** los clientes con contrato `Month-to-month` abandonan más que los de contrato anual o bianual, por tener menor compromiso.
2. **H2 – Antigüedad:** la tasa de abandono es mayor en los primeros meses de relación y disminuye a medida que aumenta `tenure`.
3. **H3 – Precio:** los clientes que abandonan pagan, en promedio, un `MonthlyCharges` más alto que los que permanecen.
4. **H4 – Servicios de soporte:** los clientes sin `TechSupport` ni `OnlineSecurity` abandonan más que quienes los contratan.
5. **H5 – Método de pago:** quienes pagan con `Electronic check` presentan mayor abandono que quienes usan pagos automáticos.

Clasificación del Dataset y Variables

Según su estructura (estructurado, semi-estructurado o no estructurado)

Identificación y justificación del tipo de datos según su estructura

Tipo de estructura identificada: estructurado.

El dataset *Telco Customer Churn* contiene 7.043 registros y 21 atributos sobre clientes de una empresa de telecomunicaciones. Está organizado en formato en tabla, donde cada fila representa un cliente y cada columna un atributo con un tipo de dato definido.

Justificación:

- **Organización en filas y columnas:** cada fila es un registro único (identificado por `customerID`) y cada columna un atributo, lo que permite consultarlo, filtrarlo y agruparlo.
- **Esquema fijo y homogéneo:** todos los registros comparten exactamente las mismas 21 columnas, en el mismo orden y con el mismo tipo de valor.
- **Ausencia de estructuras anidadas o etiquetadas:** no hay claves, jerarquías ni metadatos embebidos como en un JSON, por lo que no es semiestructurado.
- **Ausencia de contenido libre o multimedia:** no hay texto libre, imágenes, audio ni video, por lo que no es no estructurado.

Conclusión:

- por su organización tabular, esquema uniforme y tipos de dato definidos, el conjunto de datos es **estructurado**

Según tipo de variable

clasificación de variables por columna:

Columna	Tipo de variable	Justificación
`customerID`	Cualitativa nominal	Es una etiqueta de identificación, sin orden ni valor analítico. Solo sirve para distinguir registros.
`gender`	Cualitativa nominal	`Male` / `Female`, sin orden natural.
`SeniorCitizen`	Cualitativa nominal	Aunque viene como 0/1, son códigos de una categoría (sí/no). No tiene sentido sumarlos ni promediarlos como cantidades.
`Partner`	Cualitativa nominal	`Yes` / `No`.

Columna	Tipo de variable	Justificación
`Dependents`	Cualitativa nominal	`Yes` / `No`.
`tenure`	Cuantitativa discreta	Meses completos como cliente: valores enteros, no admite valores intermedios (no hay "3,5 meses").
`PhoneService`	Cualitativa nominal	`Yes` / `No`.
`MultipleLines`	Cualitativa nominal	`Yes` / `No` / `No phone service`, sin orden entre categorías.
`InternetService`	Cualitativa nominal	`DSL` / `Fiber optic` / `No`: son tipos de servicio, sin jerarquía definida en los datos.
`OnlineSecurity`	Cualitativa nominal	`Yes` / `No` / `No internet service`.
`OnlineBackup`	Cualitativa nominal	Ídem.
`DeviceProtection`	Cualitativa nominal	Ídem.
`TechSupport`	Cualitativa nominal	Ídem.
`StreamingTV`	Cualitativa nominal	Ídem.
`StreamingMovies`	Cualitativa nominal	Ídem.
`Contract`	Cualitativa **ordinal**	`Month-to-month` < `One year` < `Two year`: hay un orden lógico por duración del compromiso, pero la distancia entre categorías no es una cantidad exacta para el análisis.
`PaperlessBilling`	Cualitativa nominal	`Yes` / `No`.
`PaymentMethod`	Cualitativa nominal	Cuatro métodos de pago, ninguno "mayor" que otro.
`MonthlyCharges`	Cuantitativa continua	Monto monetario con decimales, puede tomar cualquier valor dentro de un intervalo.
`TotalCharges`	Cuantitativa continua	Ídem, es un monto acumulado.
`Churn`	Cualitativa nominal	`Yes` / `No`.

Resumen:

Tipo	Cantidad	Columnas
Cualitativa nominal	17	todas las categóricas y binarias, más `customerID`

Tipo	Cantidad	Columnas
Cualitativa ordinal	1	`Contract`
Cuantitativa discreta	1	`tenure`
Cuantitativa continua	2	`MonthlyCharges`, `TotalCharges`

Tipo de dato asignado segun pandas para cada columna

datos por defecto del dataset:

	0
customerID	object
gender	object
SeniorCitizen	int64
Partner	object
Dependents	object
tenure	int64
PhoneService	object
MultipleLines	object
InternetService	object
OnlineSecurity	object
OnlineBackup	object
DeviceProtection	object
TechSupport	object
StreamingTV	object
StreamingMovies	object
Contract	object
PaperlessBilling	object
PaymentMethod	object
MonthlyCharges	float64
TotalCharges	float64
Churn	object

datos luego de la limpieza

Columna	Tipo antes de la limpieza (Crudo)	Tipo después de la limpieza	Justificación del cambio
`customerID`	`object`	`object`	Se mantiene como texto (identificador unívoco).
`gender`	`object`	`object`	Texto descriptivo.

Columna	Tipo antes de la limpieza (Crudo)	Tipo después de la limpieza	Justificación del cambio
`SeniorCitizen`	`int64`	`int64`	Numérico crudo de origen, conceptualmente binario.
`tenure`	`int64`	`int64`	Entero correcto (meses de antigüedad).
`MonthlyCharges`	`float64`	`float64`	Correcto (monto decimal mensual).
`TotalCharges`	**`object`** *(por los espacios en blanco)*	**`float64`**	**Es el cambio crítico:** pasa de texto a float tras limpiar las cadenas vacías y castearlo.
Resto de categóricas	`object`	`object`	Variables nominales y ordinales de texto.

Conclusión del Apartado: Fundamentos, Ingesta y Limpieza de Datos

- **Problema de Negocio:** Se aborda la problemática de la pérdida de ingresos por la baja voluntaria de clientes (*churn*). Dado que adquirir un cliente nuevo es más costoso que retener uno actual, el objetivo es identificar qué perfiles, servicios y condiciones comerciales impulsan el abandono para diseñar estrategias de retención focalizadas.
- **Calidad de los datos:** Si bien el dataset cuenta con 7.043 registros y aparente integridad, una inspección profunda reveló anomalías críticas: 11 valores en blanco en `TotalCharges` ocultos como texto (correspondientes a clientes con `tenure = 0`), variables categóricas redundantes (`No phone service` / `No internet service`), y un desbalance de clases (~73.5% sin churn vs. ~26.5% con churn). Su tratamiento mediante casteo a numérico e imputación/filtrado es condición indispensable para evitar sesgos analíticos.
- **Variable Objetivo:** Se identifica a `Churn` (cualitativa nominal binaria: *Yes*/*No*) como la etiqueta central a explicar, la cual orientará tanto el análisis exploratorio como el posterior modelado predictivo.
- **Hipótesis Analíticas:** Se plantearon cinco supuestos lógicos y contrastables:

1. *H1:* Mayor abandono en contratos flexibles (*Month-to-month*) por menor compromiso.
2. *H2:* Mayor tasa de baja concentrada en los primeros meses de antigüedad (`tenure`).
3. *H3:* Asociación directa entre cargos mensuales (`MonthlyCharges`) más altos y el abandono.
4. *H4:* Mayor propensión a la baja en clientes sin servicios de soporte técnico o seguridad online.

5. *H5:* Mayor tasa de churn en quienes utilizan métodos de pago manuales (*Electronic check*) frente a débitos automáticos.

C. Preprocesamiento y Modelado Predictivo

1. Introducción

En esta etapa se aplicaron técnicas de preprocesamiento y aprendizaje automático sobre el conjunto de datos *Telco Customer Churn*, con el objetivo de realizar predicciones a partir de la información de los clientes.

Se desarrollaron dos modelos: uno de regresión para estimar una variable numérica y otro de clasificación para predecir si un cliente abandonó o no la empresa.

2. Preprocesamiento de los datos

2.1. Tratamiento de valores faltantes

Se convirtió la columna `TotalCharges` a un tipo de dato numérico mediante `pd.to_numeric()`, utilizando el parámetro `errors="coerce"` para transformar los valores que no pudieran convertirse en valores numéricos ausentes (`NaN`).

Para el modelo de regresión se eliminaron los registros que presentaban valores faltantes en las variables utilizadas. Para el modelo de clasificación se empleó `SimpleImputer` para completar los valores ausentes mediante la mediana en las variables numéricas y la categoría más frecuente en las variables categóricas.

2.2. Codificación de variables categóricas

Se utilizó `OneHotEncoder` para convertir las variables categóricas en representaciones numéricas compatibles con el algoritmo de clasificación.

Esta transformación permite incorporar atributos como `Contract`, `InternetService` y `PaymentMethod` al modelo sin establecer un orden artificial entre sus categorías.

Se configuró `handle_unknown="ignore"` para gestionar categorías que pudieran aparecer durante la transformación y que no estuvieran presentes al ajustar el codificador.

2.3. Estandarización de variables numéricas

Se utilizó `StandardScaler` para estandarizar las variables cuantitativas del modelo de clasificación. Este procedimiento transforma los valores para que cada variable tenga una media cercana a cero y una desviación estándar cercana a uno, considerando los datos utilizados para ajustar el escalador.

El preprocesamiento se integró en un `Pipeline`, de modo que los parámetros de imputación, codificación y estandarización se aprendieran exclusivamente a partir del conjunto de entrenamiento.

2.4. División de los datos

Para el modelo de clasificación, el conjunto de datos se dividió en un 80 % para entrenamiento y un 20 % para evaluación mediante `train_test_split`.

Se utilizó `stratify=y` para conservar aproximadamente la proporción de las clases `Yes` y `No` en ambos conjuntos. Además, se estableció `random_state=42` para facilitar la reproducibilidad de los resultados.

3. Predicción numérica: regresión lineal simple

3.1. Objetivo

Se implementó un modelo de regresión lineal simple para estimar el valor de `TotalCharges`, correspondiente al cargo acumulado de cada cliente.

Se seleccionó `tenure`, que representa la antigüedad del cliente en meses, como única variable predictora.

3.2. Entrenamiento

Se utilizó la clase `LinearRegression` de Scikit-learn. El modelo se entrenó con el conjunto de entrenamiento y posteriormente se generaron predicciones sobre los registros reservados para evaluación.

3.3. Evaluación

El rendimiento se evaluó mediante dos métricas:

- **Coeficiente de determinación (R^2):** permite evaluar qué proporción de la variabilidad de la variable objetivo explica el modelo en el conjunto de evaluación.
- **Error Absoluto Medio (MAE):** mide la magnitud promedio de los errores absolutos entre los valores estimados y los valores reales.

Resultados obtenidos:

- R^2: 0.68
- MAE: 877.35

Este modelo constituye una aproximación inicial a la estimación de cargos acumulados. Su principal limitación es que utiliza únicamente la antigüedad del cliente, sin considerar otros factores como el cargo mensual o los servicios contratados.

4. Predicción categórica: regresión logística

4.1. Objetivo

Se implementó un modelo de Regresión Logística para predecir la variable `Churn`, que indica si un cliente abandonó la empresa (`Yes`) o permaneció en ella (`No`).

Se utilizaron las variables disponibles como predictoras, excluyendo `customerID`, ya que se trata de un identificador individual y no de una característica explicativa del cliente.

4.2. Entrenamiento

El modelo se implementó mediante `LogisticRegression`, integrado en un `Pipeline` que incluye las etapas de imputación, codificación y estandarización.

El entrenamiento se realizó sobre el 80 % de los datos, mientras que el 20 % restante se reservó para evaluar las predicciones sobre registros que el modelo no había utilizado para aprender.

4.3. Resultados de la evaluación

Se obtuvo una exactitud (*Accuracy*) de **0,8055**, equivalente aproximadamente al 80,55 % de predicciones correctas.

La matriz de confusión fue la siguiente:

Resultado real / Predicción	No	Yes
No	926	109
Yes	165	209

La matriz permite identificar los aciertos y errores del modelo:

- **926 verdaderos negativos:** clientes que permanecieron en la empresa y fueron identificados correctamente.
- **109 falsos positivos:** clientes que permanecieron, pero fueron clasificados como posibles abandonos.
- **165 falsos negativos:** clientes que abandonaron, pero fueron clasificados como clientes que permanecerían.
- **9 verdaderos positivos:** clientes que abandonaron y fueron identificados correctamente.

4.4. Informe de clasificación

Las métricas obtenidas fueron las siguientes:

Métrica	Clase No	Clase Yes
Precision	0,85	0,66
Recall	0,89	0,56
F1-score	0,87	0,60
Support	1.035	374

La clase `No` presenta mejores resultados que la clase `Yes`. El modelo identifica correctamente aproximadamente el 89% de los clientes que permanecieron, mientras

que detecta aproximadamente el 56% de los clientes que abandonaron.

La diferencia entre ambas clases muestra que el modelo tiene mayor dificultad para identificar los abandonos. Esto es relevante porque, en un escenario comercial, no detectar a un cliente que finalmente abandona podría representar una oportunidad perdida para implementar acciones de retención.

5. Conclusiones

En esta etapa se implementaron técnicas de preprocesamiento y dos modelos de aprendizaje automático: una regresión lineal simple para estimar una variable continua y una regresión logística para clasificar el abandono de clientes.

El modelo de clasificación alcanzó una exactitud del 80,55 % en el conjunto de evaluación. Sin embargo, su capacidad para detectar clientes que abandonan es inferior a su capacidad para identificar a quienes permanecen.